

SRP-PINN：物理信息神经网络 模拟回流焊热曲线

SRP-PINN: A Physics-Informed Neural Network Model for Simulating Thermal Profile of
Soldering Reflow Process

把传热 PDE 嵌入神经网络损失函数：210 个实测点、单配方训练，跨板型跨配方预测
精度达 98%

汇报用途：文献阅读汇报 · 单篇精读

论文基本信息

中文标题：SRP-PINN：物理信息神经网络模拟回流焊热曲线模型

期刊与收录

IEEE Transactions on CPMT · 2024 年 Vol. 14, Issue 6, pp. 1098-1105

→ **SCIE Q2 · IF 3.3 · EI 收录 · 中科院 3 区**

作者团队（宾汉姆顿大学）

A Farrag · J Kataoka · S W Yoon · D Won · Y Jin

→ **DOI: 10.1109/TCPMT.2024.3399109**

关键词

PINN · PCB · 回流焊 SRP · 热曲线预测

→ → **有限数据下的物理约束代理建模**



IEEE Transactions on CPMT 期刊封面（装饰图）

Source: 期刊封面, IEEE Trans. CPMT, 2024

汇报目录

01 • 背景与挑战

热曲线必须精确匹配，传统方法两难

02 • 文献综述

CFD 太贵、纯 ML 要数据，混合模型受限于设计

03 • 方法

SRP-PINN：PDE 嵌入损失函数的物理约束网络

04 • 实验

单配方训练，跨板型跨配方双场景验证

05 • 结果

98% 精度 vs RF/DNN；冷却区缺口与原因

06 • 结论与展望

代理建模 + 实时监测的工业 4.0 路径

热曲线必须精确匹配：不足→虚焊，过度→元件损伤


► 如图 1 所示，为什么 '大元件够热' 与 '小元件不过热' 难以两全？

元件热质量差异大：BGA 大、0402 小，同一炉内升温速率不同；加热不足虚焊、过度则助焊剂过早激活

→ 必须精确预测板上任意位置的温度，不能只靠试错调炉温

热曲线：thermal profile：焊料温度 - 时间轨迹，制造商按成分物理性质规定目标曲线（预热 / 保温 / 回流 / 冷却）

图意：右图为 SAC305 目标热曲线：预热→保温平台→越过液相线（约 217°C）→冷却；左图为 SMT 三道工序流程



SMT 装配流程与 SAC305 目标热曲线

(a) SMT 装配工艺流程；(b) SAC305 焊膏目标热曲线

解读：目标热曲线由焊膏物理性质规定——回流段必须越过液相线且时间受控，这是全部优化与预测的基准

Source: Fig. 1, IEEE Trans. CPMT, 2024

三类现有方法：精度、成本与数据不可兼得

现有方法在数据成本与泛化能力之间难以两全


- CFD/FEA：每换配方或板型都要重新网格计算
- 纯 ML：需要大量高质量实验数据覆盖工况

混合物理 -ML（Li 等）精度 97%，但受限于特定板卡设计

方法	精度	数据 / 计算成本	主要局限
CFD / FEA	高	小时级网格计算	换工况全重算，不通用
纯 ML（RF/DNN）	稀疏数据下失准	需大量实验数据	数据稀疏时无法学习
混合物理 -ML	97%	仿真数据 + CFD	受限于特定设计 / 几何
SRP-PINN（本文）	98%	210 点 · 单配方	冷却区预测有缺口

PINN 不依赖网格离散，物理方程本身作为训练约束——数据少也能学

方法总览： PDE 嵌入损失函数的物理约束网络



SRP-PINN 框架总览：(a) 系统建模 (b) 炉空气温度拟合 (c) PINN 架构
解读：板温由对流边界从炉温驱动—— T^a 是驱动源，网络输出即板温分布
Source: Fig. 2, IEEE Trans. CPMT, 2024

系统建模：从 N-S 方程到能量守恒的四组控制方程

质量守恒： $\nabla \cdot \mathbf{u} = 0$

不可压缩空气流入 = 流出

→ 气流场无源无汇

动量守恒（Navier–Stokes）

$$\rho^a(\partial \mathbf{u} / \partial t + (\nabla \cdot \mathbf{u})\mathbf{u}) = -\nabla \cdot \mathbf{P} + \mathbf{F} + \mu \nabla^2 \mathbf{u}$$

→ 决定热空气到板面的流量分布

能量守恒 • 空气侧

$$\rho^a C_p^a (\partial T^a / \partial t + \dots) = k^a \nabla^2 T^a + (\nabla \cdot \mathbf{P})\mathbf{u} + \mu \Phi_T$$

→ 设定炉温 T_r 经气流传播

能量守恒 • 板侧（含潜热）

$$\rho^b C_p^b \partial T^b / \partial t = k^b \nabla^2 T^b + \dot{Q} - \rho^b L \cdot \partial f_l / \partial t$$

→ 焊料相变吸放热 → 液相线平台

五项简化假设 → 两条核心 PDE

简化热传导方程（核心 PDE）

$$\partial T^b / \partial t - (k^b / \rho^b C_p^b) \cdot \partial^2 T^b / \partial x^2 = 0$$

→ **PINN 必须满足的物理规律**

上表面对流边界条件

$$h(T^a - T^b) - k^b \cdot \partial T^b / \partial x = 0$$

→ 炉温 T^a 是驱动源， h 是换热强度

五项简化假设

忽略反应热与潜热；仅上边界对流；1-D 沿板长；炉温线性 / 多项式拟合

→ 换来计算效率与可训练性

潜热 L 为何可忽略：板温远达不到板的熔化温度，潜热项对板消失；单焊膏反应热相对对流 / 传导热量极小

对流系数 h 自适应估计：关键热区与冷却区的精度来源

h 不是固定常数，而是随工况动态更新

- $h = k^b \cdot q_A / (A^b[(T_2^b - T_1^b)t_z + T_o^b])$
- 由实测板进出口温度与处理时间反推

各区 $h \in 35\text{--}64 \text{ W/m}^2/\text{K}$ ，冷却区 35 最低、2 区 64 最高

温区	配方温度 T_r [°C]	吸收热 q_A	h [W/m²/K]
1	90	2662	53
2	131	1477	64
3	172	1259	62
4	182	831	57
5	190	482	49
6	237	1641	51
7	280	672	52
8（冷却）	95	5007	35

换热系数随温区显著变化——固定 h 的模型无法准确捕捉关键热区与冷却区

PINN 架构：小网络 + 物理约束 = 强泛化

10 层 × 10 神经元，821 参数

学习率 10^{-4} ，500 epochs；PDE 平均 log 损失 $0.1 \rightarrow 10^{-12}$

→ 相比 FE 无需网格，训练后预测毫秒级

隐藏层 tanh、输出层 Softplus

tanh 平滑可微适合多次微分；Softplus 输出恒正

→ 保证预测温度 T^b 恒为正

输入 (x, t, T^a) ，输出板温 T^b

位置、时间、炉空气温度 → 板上任意点任意时刻温度

→ 一次训练，全板全时段热曲线可查

PINN：物理信息神经网络：把 PDE 残差加入损失函数，网络学到的解天然满足物理规律

损失函数五元组：数据拟合 + 四条物理约束

$$L_{\text{total}} = L_{\text{data}} + L_{\text{T}} + L_{\text{IC}} + L_{\text{bc1}} + L_{\text{bc2}}$$

五项均方误差之和，对所有训练点 m 求和

→ 物理信息经后四项注入网络

PDE 残差损失 L_{T}

$\partial T^b / \partial t$ 与 $\alpha \cdot \partial^2 T^b / \partial x^2$ 之差的均方

→ 网络解必须满足热传导方程

初始条件 L_{IC}

$t=0$ 时预测等于初始温度 T_0^b

→ 锚定时间方向起点

边界条件 $L_{\text{bc1,2}}$

$x=0, l$ 处满足对流边界 $hT^b - k^b \partial T^b / \partial x = 0$

→ 时空域解唯一且物理一致

自动微分：PDE 残差中的导数由网络反向传播精确计算，无需差分近似

实验设置： 210 个实测点、单配方训练的极端数据约束

如图 3 所示，210 个实测点 · 单配方训练

Heller 1707W 炉 · K 型热电偶 ($\pm 1^{\circ}\text{C}$) · SAC305 焊膏 · 每 2 s 采样

→ 以往研究每秒采集 420 s 全周期，本文数据量大幅缩减

两种板卡设计验证泛化


板 #1：1500 个无源元件 (0402/0603/1005)；板 #2：BGA 元件

→ 场景一跨板型 + 场景二跨配方

训练用板 #1 的 A/D/C 三个位置

1-D 传热沿板长方向，5 个采集位置取 3 个参与训练

→ 验证板上任意位置的可迁移性




实验设置：(a) 板 #1（无源元件）(b) 板 #2（BGA）
(c) Heller 1707W 回流炉

解读：两种板型覆盖了 SMT 产线的典型场景——无源元件板与 BGA 板

Source: Fig. 3, IEEE Trans. CPMT, 2024

结果 1：炉温拟合方式决定边界驱动源精度

多项式拟合炉空气温度显著优于线性拟合



多项式与线性炉温拟合的热曲线预测对比

解读：边界驱动源 T^a 的建模精度直接决定 PINN 输出精度——驱动源不平滑，输出就不准

Source: Fig. 4, IEEE Trans. CPMT, 2024

如图 4 所示，多项式拟合接近真实炉内温升特性，预测精度令人满意

- 线性拟合引入阶跃尖角，与真实气流行为不符
- 测试板 #2 · 测试配方 #1 下对比

多项式拟合 → 热曲线预测满足精度要求


坐标轴：横轴：时间（回流全程约 420 s）；纵轴：温度（°C）

图例：实测曲线与多项式 / 线性两种拟合的预测曲线对比

图意：多项式拟合与实测基本重合，线性拟合在温升段明显偏离

结果 2：RF 与 DNN 在关键热区失准，SRP-PINN 全程稳定

有限数据下 RF/DNN 学不动，PINN 靠物理约束保持精度



SRP-PINN 与 RF、DNN 模型的热曲线预测对比

解读：差异集中在温升最快的 6/7 区与温降最快的 8 区——纯数据驱动模型在这些高动态区最脆弱

Source: Fig. 5, IEEE Trans. CPMT, 2024

如图 5 所示，SRP-PINN 在整个 SRP 过程保持满意精度


- RF 与 DNN 在关键加热区（6/7 区）与冷却区（8 区）显著失准
- 210 点小样本不足以让纯数据驱动模型学习热行为

SRP-PINN 精度 98% vs 混合物理 -ML 基准 97%

坐标轴：横轴：时间；纵轴：温度（℃）
图例：实测 / SRP-PINN / RF / DNN 四条曲线对比
图意：关键加热区（6/7 区）与冷却区（8 区）RF 与 DNN 偏离实测最大，SRP-PINN 全程贴合

结果 3：输出全板 1-D 热分布，任意位置可查焊膏热曲线

一次训练获得全板温度场，换边界 / 换热系数 / 板型无需重算网格



各炉区特定时刻 PCB 沿板长方向（140 mm）的预测热分布

解读：1-D 热分布曲线平滑合理——物理约束抑制了数据驱动模型常见的波动

Source: Fig. 6, IEEE Trans. CPMT, 2024

如图 6 所示，PCB 热分布预测被约束在合理范围，无 RF/DNN 的剧烈波动

- 沿板长 140 mm 各炉区特定时刻的温度分布
- 板上任意位置焊膏热曲线可参照热分布估计

FE 换 BC/ 换热系数 / 板型需重算；PINN 只需少量数据重训

坐标轴：横轴：板长位置（0–140 mm）；纵轴：温度（°C）

图例：各炉区特定时刻的温度分布曲线

图意：温度沿板长平滑分布且被约束在合理范围，无数数据驱动模型的剧烈波动

结果 4：单配方训练跨配方泛化，冷却区缺口诚实披露

如图 7 所示，跨配方泛化成立，冷却区是共同短板

- 测试配方 #1/#2/#3 均未出现在训练集
- 冷却区 100 s 内 270→95℃，采样点不足捕捉冷却速率

同板型跨配方精度优于跨板型场景


坐标轴：横轴：时间；纵轴：温度（℃）

图例：训练配方与三个测试配方的预测 vs 实测对比

图意：加热段三个测试配方贴合良好，冷却段（270→95℃）均出现预测间隙

配方	1 区	2 区	3 区	4 区	5 区	6 区	7 区	8 区
训练	90	131	172	182	190	237	280	95
测试 1	103	130	168	188	198	242	270	95
测试 2	95	131	175	185	195	220	260	150
测试 3	90	120	152	160	170	195	217	125

训练配方与三个测试配方差异明显——加热区温度最大差 63℃



相同 PCB 设计下不同测试配方的 SRP-PINN 评估
解读：加热段预测贴合良好，冷却段三个配方均出现预测间隙——局限性的诚实披露
Source: Fig. 7, IEEE Trans. CPMT, 2024

结论与展望：从代理建模到实时监测

有限数据准确预测

210 实测点训练，跨板型跨配方预测热曲线

→ 不依赖网格离散，训练后预测毫秒级

方法独特价值

为 SRP 代理建模、实时监测、参数优化提供可行实现

→ 集成进回流炉可简化温度优化流程

未来方向

1-D 扩展到 2-D/3-D，纳入元件位置与密度

→ 需权衡精度提升与训练成本上升

核心要点：物理约束如何补数据之不足

物理损失 = 数据之外的信息源

PDE 残差在无数据时空点依然约束温度演化

→ 少量数据 + 强物理 = 全时空域合理预测

数据效率是核心卖点

210 点单配方 → 98% 精度，跨板型跨配方泛化

→ 工业实测数据采集成本高，数据效率直接决定可行性

诚实披露局限

冷却区缺口源于冷却速率数据不足

→ 高动态区需要更密的采样或更强的边界建模

对红外焊接的借鉴

红外焊接同样受传热方程支配

→ 控制方程作约束 + 少量实测点训练 → 热曲线模拟与实时温控代理